

110612117 張仲瑜 HW4 report

1. Describe your understanding and findings about the attention


mechanism by exBERT. (20%)

使用句子: Breathing fresh air in the forest is refreshing.

使用 model: distilbert-base-uncased

可以發現這個工具同一個單字選取左手邊會出現它對其他單字預測的貢獻

選取右手邊為其他單字對該單字對它的貢獻



- 先不遮任何單字，可以觀察到 layer 2 與 layer 6 比較特別，layer 2 明顯展現出不同 head 的影響，layer 6 則主要是每個詞對結尾標點的預測，以下針對這兩個 layer 做觀察分析。


■ 以下透過 Layer 2 觀察不同 head 的影響

Selected heads: 1, 10

Select all heads Unselect all heads

You focus on one token by **click**. You can mask any token by **double click**.

You can select and de-select a head by a **click** on the heatmap columns




■ Head 1、10 展現前一詞的預測影響

Selected heads: 2

Select all heads Unselect all heads

You focus on one token by **click**. You can mask any token by **double click**.

You can select and de-select a head by a **click** on the heatmap columns




Selected heads: 2

Select all heads Unselect all heads

You focus on one token by **click**. You can mask any token by **double click**.

You can select and de-select a head by a **click** on the heatmap columns




■ Head 2 展現後方兩個詞語對自己的影響


Selected heads: 7

Select all heads Unselect all heads



You focus on one token by **click**. You can mask any token by **double click**.

You can select and de-select a head by a **click** on the heatmap columns






■ Head 7 展現自身影響




■ Head 6 展現 be-V、prep、冠詞、標點的影響

■ 以下將與呼吸有關的詞拿掉，查看 air 預測結果




- 明顯出現與森林有關的詞像植被、棲息地等



- 加入 refreshing 無太大改善，單獨加入 breath 或 fresh，air 機率就小

幅上升




- 前面兩者都加入，air 機率大幅上升。


■ 以下透過 Layer 6 觀察影響標點預測的因素




■ 將標點遮住，可以發現附近的 be 動詞與形容詞對預測影響較大，造就了 84% 的預測為”.”、13% 為”,” 等機率分布




■ 在後方新增單詞觀察其對預測的影響，當後方出現其他詞時，句號的預測與其他的差距下降許多。





- 當後方出現連接詞時，對標點也會有明顯貢獻，可以看到逗號機率上升許多。




- 加上程度副詞，可以發現受到其影響，驚嘆號出現在前幾預測中。
- 綜合以上實驗可以發現，儘管出現的預測有時不是我們的輸入，但都可以跟上下文接得起來，由此可知 distilbert-base-uncased model 的確有根據上下文產生預測的機率分布。

2. Compare at least 2 sentiment classification models (e.g.,

TA_model_1.pt, your model in HW2). (30%)


■ 以下使用 Lime 進行比較(先 model 1 再 model 2)


■ 句中混用正負面語句



■ 兩者對詞皆有強烈強弱之分，fantastic 在 boring 面前遭到輾壓，

Model 1 尤為明顯





■ 兩者皆對放在前面的詞有較高的權重，model 2 此點超級明顯，

將 fantastic 與 boring 對調直接改變了結果




- 轉折能夠有使後方形容詞更強，加上轉折語就變成正面了

model 1 在轉折語本身給的力度較高

model 2 相比 model 1 更偏向轉折點後方的形容詞加強

- 隱晦敘述




- model 1 雖然 full 被判斷成高權重正面，但整句話被成負面，這裡

應該不是因為沒位子坐而判斷為負面，否則 full 應該判斷為負面

model 2 雖然 full 的權重沒那麼高，但整句話被判斷成正面

為了去除前後因素影響，將 model 順序調換再做確認




仍然判斷為正面

- 小結: model 1 對字有強烈強弱標準，對句子會以整句話進行判斷，但對隱晦的長句易失真，整句而言正負面分類較保守；model 2 則易受順序性影響，對轉折語也較敏銳，整句而言正負面較分明

3. Compare the explanation of LIME and SHAP. (30%)

- 以下使用 model 1 進行比較 (先 LIME 再 SHAP)
- 詞強弱分析




- Boring: 8.707、Fantastic 3.607，Boring 更加強烈

LIME 和 SHAP 兩者都認為詞有強弱區別，且比起 fantastic 將

Boring 視為更加強烈的一者

■ 轉折語分析




- LIME 與 SHAP 皆將轉折語視為後方形容詞的正負面；

LIME 給轉折語的造成的影響力(1:4)略較 SHAP(1:6)高

前為轉折語影響，後為形容詞本身影響


- 雙重否定分析




- LIME 將雙重否定視為兩者皆貢獻正面；SHAP 則將反轉否定視為大量正面貢獻，後方否定形容則照舊貢獻負面

我個人喜歡 LIME 的分析一點，更強烈形容詞在反義時也理當更強烈。

- 人與環境衝突狀況



- LIME 解釋傾向人的感受，儘管 raining 的負面值相當高，仍然給出相當高的正面預測機率；SHAP 部分整體正面小勝負面，good 的影響高過於 raining。
- 一詞多詞性、疑問句




- LIME 認為該問句較負面，SHAP 則幾乎採中立，略偏負面
- 小結: 兩者在不同情況皆有不同詮釋，LIME 比較容易將普通詞彙視為略負面的標籤，但對正負面詞彙的加減分比較明顯；SHAP 的詮釋除非是明顯極端偏向，否則略為平均一點。


4. Try 3 different input sentences for attacks. Also, describe your findings and how to prevent the attack if you retrain the model in the future. (20%)

- 原始正面句子: What a great show!


■ 下列為將句子的標點更改為疑問句的多種攻擊




■ 原始狀態



■ 加上, sure? 對 LIME 影響效果不大，對 SHAP 則稍微拉向中利




- 加上 Is that ...? 相當出乎意料地完全沒用，負面貢獻極低，也沒有影響到正面字的發揮



- 加上一堆?在句尾 問號越多效果越大，5 個接近中立，更多就變負面。

- 下列為將貢獻度較高的字破壞的多種攻擊



- 將前兩個字母拼字對調，成功改變預測結果

制，也透過圖像化的工具對 multi head attention 有了更詳細的
解，比起抽象的矩陣運算，圖像化可以透過觀察結果加強我的印
象，覺得受益良多，算是這學期所有作業裡面我印象的一次作業。